

CLASSIFICAZIONE

Progetto ML: IBM HR Attrition

Prevedere se un dipendente lascerà l'azienda — un problema di classificazione applicato al dataset IBM HR Analytics.

Gruppo: ADABI 2025-2026
Olga Shopieva [portfolio GitHub](#)
Progetto su [GitHub](#) (+attività AWS)
Google Colab [Notebook](#)
[Dataset](#)



IL DATASET

Il Dataset

Ogni riga rappresenta un dipendente con informazioni su età, stipendio, ruolo, soddisfazione e molto altro.

1

Dati anagrafici

Age, Gender, MaritalStatus, Education

2

Dati professionali

JobRole, Department, JobLevel, YearsAtCompany

3

Soddisfazione e stipendio

JobSatisfaction, MonthlyIncome, OverTime

OSSERVAZIONI TOTALI

1.470

righe nel dataset

COLONNE

35

VALORI MANCANTI

0

VARIABILE TARGET

Attrition (Yes / No)

Classe No

84% · 1.233

Classe Yes

16% · 237

PULIZIA DELLE FEATURE

Colonne eliminate e motivazioni

eliminate le colonne non informative per evitare rumore e data leakage.

Valori costanti

EmployeeCount, Over18, StandardHours

Identificativo (data leakage)

EmployeeNumber

Ridondanti con MonthlyIncome

DailyRate, HourlyRate, MonthlyRate

Feature prima e dopo

35 → 28

colonne originali

feature finali

— 7 colonne eliminate —

TRASFORMAZIONE TARGET

Attrition
"Yes" / "No" → 1 / 0

testo

numerico

ANALISI ESPLORATIVA (EDA)

Chi lascia l'azienda?

Tre pattern emergono con chiarezza dall'analisi del training set.

Eta e reddito piu bassi

I dipendenti che partono tendono ad essere piu giovani e con MonthlyIncome inferiore.

Straordinario come segnale

OverTime = Yes e fortemente associato a un tasso di Attrition piu elevato.

Correlazioni deboli

Nessuna variabile numerica ha $|r| > 0.20$: necessaria la combinazione di piu fattori.

Correlazione con Attrition

Correlazione di Pearson (valori numerici)

CORRELAZIONE POSITIVA

DistanceFromHome		+0.09
NumCompaniesWorked		+0.05

CORRELAZIONE NEGATIVA

TotalWorkingYears		-0.19
Age		-0.19
YearsWithCurrManager		-0.17
JobInvolvement		-0.13

PREPROCESSING

Preparazione dei dati

Preparazione dei dati per i modelli di Machine Learning.

1

Split stratificato

80% training (1.176 righe) e 20% test (294 righe).

`stratify=y · random_state=42`

2

One-Hot Encoding

7 variabili categoriche trasformate in colonne 0/1.

28 → 41 feature totali

3

Standardizzazione

StandardScaler: media 0, deviazione standard 1.

Fondamentale per la Regressione Logistica

4

`class_weight="balanced"`

Compensa lo sbilanciamento 84% / 16% dando più peso alla classe minoritaria.

MODELLO 1

Regressione Logistica

Modello semplice e interpretabile, buon punto di partenza per la classificazione binaria.

TUNING SOGLIA (CROSS-VAL 5-FOLD)

Soglia 0.4	F1: 0.452
Soglia 0.5	F1: 0.494
Soglia 0.6 (scelta)	F1: 0.549

Scelta: soglia 0.6

Miglior F1 (0.527) con buon equilibrio Precision / Recall

MODELLO 2

Random Forest

300 alberi decisionali, piu complesso ma capace di catturare interazioni non lineari.

TUNING SOGLIA (CROSS-VAL 5-FOLD)

Soglia 0.2 (scelta)	F1: 0.529
Soglia 0.3	F1: 0.472
Soglia 0.4	F1: 0.420

Scelta: soglia 0.2


RF e piu conservativo: serve soglia bassa per un recall comparabile

RISULTATI SUL TEST SET

Risultati sul Test Set

La Regressione Logistica ottiene il miglior equilibrio complessivo.

MODELLO	ACCURACY	PRECISION	RECALL	F1-SCORE	ROC-AUC
Regressione Logistica soglia 0.6 · vincitore	82.7%	46.7%	59.6%	52.3%	81.7%
Random Forest 300 alberi · soglia 0.2	77.6%	38.3%	66.0%	48.4%	78.2%



CONCLUSIONI

Risultati e prossimi passi

COSA ABBIAMO FATTO

- Esplorazione, pulizia e analisi del dataset IBM HR
- Split stratificato, One-Hot Encoding, standardizzazione
- Confronto Regressione Logistica vs. Random Forest
- Feature importance: reddito, eta, straordinari

LIMITI DEL MODELLO

Dataset piccolo (1.470) e sbilanciato: la classe Yes ha pochi esempi, il recall sulla minoranza rimane il limite principale.

SVILUPPI FUTURI

1

Tuning iperparametri

GridSearchCV o RandomizedSearchCV per ottimizzare n_estimators, max_depth e altri.

2

Modelli piu avanzati

Gradient Boosting, XGBoost per migliorare le performance sulla classe minoritaria.

3

Feature engineering

Nuove variabili derivate (es. rapporto anni nel ruolo vs. anzianita totale).

Applicazione HR

Sistema di early warning per identificare i dipendenti a rischio di abbandono e supportare la retention.



INTELLIGENZA ARTIFICIALE

AI usata in questo progetto

- 1 Google Gemini 3.5 Flash (per generare title image nella presentazione)
- 2 Claude Sonnet 5 (per il codice notebook)
- 3 replit.com (per creare presentazione Power Point)

L'elenco completo degli obiettivi e i prompts sono disponibile al seguente [link](#)